

## **VISIONAI TRAFFIC: SISTEMA INTELIGENTE DE DETECCIÓN Y SEGUIMIENTO URBANO**

### **CONTEXTO DE LA APLICACIÓN**

La movilidad en áreas urbanas se enfrenta a desafíos complejos, como el aumento del tráfico y la necesidad de una gestión más eficiente de las vías para garantizar una circulación fluida y segura. Este proyecto se centra en la detección y seguimiento de objetos en imágenes obtenidas de cámaras de tráfico, con el objetivo de crear un sistema automatizado que permita identificar vehículos, peatones y señales de tráfico. Esta solución puede ser crucial en la mejora de la gestión del tráfico, la prevención de accidentes, y la planificación urbana, así como en la implementación de sistemas de gestión de tráfico basados en inteligencia artificial, contribuyendo al desarrollo de ciudades inteligentes.

### **OBJETIVO DE MACHINE LEARNING**

El objetivo principal de machine learning de este proyecto es la detección y seguimiento de objetos dentro de imágenes capturadas por cámaras de tráfico. Queremos identificar vehículos, peatones y señales de tráfico en diferentes condiciones climáticas e iluminación; para posteriormente, analizar el tráfico y predecir situaciones de congestión. Este enfoque busca desarrollar un modelo que, a partir de una imagen de tráfico, pueda detectar objetos de interés, y utilizar esta información para inferir la densidad del tráfico y anticipar posibles congestiones, proporcionando una herramienta valiosa para mejorar la planificación y gestión urbana.

### **DATASET (Saridoğan, 2023)**

- **Tipo de datos:** Imágenes de cámaras de tráfico (640 x 640 píxeles), con anotaciones que incluyen cuadros delimitadores para la identificación de objetos (vehículos, peatones y señales de tráfico).
- **Tamaño:** El dataset consta de 6500 imágenes de 640 x 640 píxeles cada una. El tamaño total del dataset en disco es de aproximadamente 1.2 GB.
- **Distribución de las clases:** Cada imagen incluye múltiples anotaciones que identifican vehículos, peatones y señales de tráfico. Cada imagen puede tener una cantidad variable de cada clase, lo cual permite modelar un escenario complejo de tráfico urbano. Consideramos a los vehículos como la clase dominante.

### **MÉTRICAS DE DESEMPEÑO**

- **IOU:** Calcula la superposición entre el bounding box predicho y el real, midiendo cuán bien el modelo delimita el objeto correcto. IOU es fundamental en este proyecto, ya que queremos que los cuadros delimitadores se ajusten de la mejor manera posible a los objetos reales.

- **Mean Average Precision (mAP):** Es una métrica comúnmente utilizada para evaluar el rendimiento de los modelos de detección de objetos. Calcula el promedio de la precisión en todas las clases y se utiliza para medir la capacidad del modelo de detectar correctamente varios tipos de objetos. Es útil con múltiples categorías, como en este caso con vehículos, peatones, y señales de tráfico (Chauhan, 2023).

## MÉTRICAS DE NEGOCIO

1. **Reducción del tiempo de congestión vehicular:** Esta métrica evalúa el impacto del sistema en la mejora de la gestión del tráfico. Al detectar y predecir congestiones de manera más eficiente, se puede reducir el tiempo que los vehículos pasan en tráfico, mejorando la movilidad urbana y reduciendo costos asociados, como el combustible y la contaminación.

### Métrica de negocio:

- **Tiempo promedio de viaje:** Esta métrica mide el tiempo promedio que los vehículos tardan en llegar de un punto a otro dentro de la red de tráfico monitoreada.

### Impacto:

- **Aumento de la eficiencia en el flujo de tráfico:** Al reducir el tiempo promedio de viaje, se mejora la movilidad urbana, disminuyen los costos por consumo de combustible y las emisiones de CO<sub>2</sub>, y se optimiza el uso de las vías.
- **Satisfacción del ciudadano:** Los conductores y usuarios del transporte público experimentan menos tiempo en tráfico, lo que mejora la calidad de vida.

2. **Mejora en la seguridad vial (reducción de accidentes)**

### Métrica de negocio:

- **Tasa de reducción de accidentes:** Esta métrica mide la disminución porcentual en la cantidad de accidentes viales en áreas monitoreadas tras la implementación del sistema.

### Impacto:

- **Reducción de costos asociados a accidentes:** Al reducir el número de accidentes, se minimizan los costos de atención médica, seguros, reparaciones de vehículos y daños a infraestructuras.
- **Mejora de la seguridad pública:** Se reduce el riesgo para peatones y conductores, mejorando la seguridad vial y, por lo tanto, generando mayor confianza en las medidas de tráfico inteligentes adoptadas por la ciudad.

## RESULTADOS PREVIOS

Estudios anteriores han demostrado que modelos de Deep Learning, como YOLO y Faster R-CNN, son efectivos en tareas de detección de objetos en escenarios de tráfico, alcanzando precisiones de detección superiores al 70% en condiciones similares (Ren, 2015). Estos trabajos previos sugieren que la combinación de técnicas de detección de objetos con análisis predictivo del tráfico puede proporcionar un sistema robusto para la gestión del tráfico urbano.

## REFERENCIAS

Saridoğan, Y. (10 de octubre de 2023). *Traffic Detection Project*. Kaggle. <https://acortar.link/dCSckq>

Chauhan, N. (25 de septiembre de 2023). *Métricas De Evaluación De Modelos En El Aprendizaje Automático*. Datasource. <https://acortar.link/Wu8igo>

Ren, S. (2015). Faster r-cnn: Towards real-time object detection with region proposal networks. arXiv preprint arXiv:1506.01497.

Kundu, R. (17 de enero de 2023). *YOLO: Algorithm for Object Detection Explained [+Examples]*. V7labs. <https://acortar.link/M19FcZ>